ESCUELA DE INGENIERÍA INFORMÁTICA



PONTIFICIA UNIVERSIDAD CATÓLICA DE VALPARAÍSO

Optimización del costo computacional de XAI en la clasificación de malware

Selección de características, destilación de conocimiento y explicación adaptativa

Rigoberto Ignacio Enrique Canales Puebla

Francisco Ignacio Espinoza Vasquez

Profesor Guía: PAMELA HERMOSILLA MONCKTON

Profesor Correferente: SEBASTIAN BERRIOS VASQUEZ

Informe de Avance Seminario

Ingeniería en Informática

4 de octubre de 2026

RESUMEN

Un clasificador puede detectar una muestra de malware en poco tiempo y, aun así, necesitar un esfuerzo considerable para explicar su decisión. Esta diferencia importa cuando se pretende revisar muchas alertas: el costo de explicar puede ser distinto del costo de predecir y debe medirse por separado. A partir del corpus de 43 fichas bibliográficas reunido para el seminario, este informe reformula una propuesta orientada a estudiar esa diferencia y a reducirla mediante una arquitectura multinivel.

La propuesta combina selección de características, destilación de conocimiento hacia un clasificador más ligero y asignación adaptativa del presupuesto de explicación. La literatura incorporada muestra que ya existen antecedentes de reducción guiada por explicabilidad, sistemas híbridos y decisiones selectivas. Por ello, el aporte se sitúa en la integración y evaluación de estos componentes bajo un protocolo común, con controles de calidad explicativa y de rendimiento predictivo.

Se plantea una evaluación sobre datos públicos de Android y ejecutables de Windows, tratados como tareas independientes. Se medirán latencia, memoria y capacidad de procesamiento, junto con macro F1, sensibilidad a malware, fidelidad y estabilidad de las explicaciones. El diseño contempla comparaciones con TreeSHAP completo, modelos entrenados directamente y ablaciones de cada componente. Este documento presenta la fundamentación y el diseño experimental; no informa resultados de un prototipo que todavía debe construirse y validarse.

Palabras clave: malware, inteligencia artificial explicable, costo computacional, destilación de conocimiento, explicación adaptativa.

ABSTRACT

A malware classifier may produce a prediction quickly while requiring substantially more work to explain it. When many alerts must be inspected, prediction time and explanation time need to be measured separately. Drawing on the 43 literature records assembled for this project, this report reformulates a proposal to investigate that distinction through a multilevel architecture.

The proposed approach combines feature selection, knowledge distillation into a lighter classifier, and adaptive allocation of an explanation budget. Related work already includes explanation-driven feature reduction, hybrid pipelines, and selective decision mechanisms. The intended contribution is therefore the integration and evaluation of these components under a common protocol, with explicit constraints on predictive performance and explanation quality.

The experimental design considers public Android and Windows executable datasets as separate tasks. It will measure latency, memory use, and throughput alongside macro F1, malware recall, explanation faithfulness, and stability. Comparisons will include full TreeSHAP, directly trained student models, and component ablations. This report presents the rationale and experimental design; it does not claim empirical improvements from an implementation that remains to be developed and validated.

Keywords: malware, explainable artificial intelligence, computational cost, knowledge distillation, adaptive explanation.

ÍNDICE GENERAL

Resumen I

Abstract II

1. Introducción 1

2. Definición del problema 2
2.1. Problema de investigación . . . 2
2.2. Pregunta e hipótesis de trabajo . . . 2
2.3. Alcance y delimitaciones . . . 2

3. Marco teórico 4
3.1. Representación y clasificación de malware . . . 4
3.2. Qué significa explicar una predicción . . . 4
3.3. SHAP y sus implementaciones . . . 4
3.4. LIME y evaluación local . . . 5
3.5. Selección, destilación y adaptación . . . 5
3.6. Calidad técnica y utilidad humana . . . 5

4. Estado del arte 6
4.1. Corpus y criterio de síntesis . . . 6
4.2. De la representación del malware a la explicación . . . 6
4.3. Modelos visuales, multimodales y eficiencia . . . 7
4.4. Reducción y clasificación explicable: antecedentes cercanos . . . 7
4.5. Adaptación, confianza y robustez . . . 8
4.6. Síntesis comparativa y aporte delimitado . . . 8

5. Objetivos 9
5.1. Objetivo general . . . 9
5.2. Objetivos específicos . . . 9

6. Metodología 10
6.1. Diseño general . . . 10
6.2. Revisión y trazabilidad bibliográfica . . . 10
6.3. Datos y prevención de fuga . . . 10
6.4. Arquitectura multinivel . . . 11
6.4.1. Nivel 1: selección de características . . . 11
6.4.2. Nivel 2: profesor y estudiante . . . 11
6.4.3. Nivel 3: explicación adaptativa . . . 12
6.4.4. Extensión de caché . . . 12
6.5. Líneas base y ablaciones . . . 12
6.6. Medición del costo computacional . . . 13

6.7. Rendimiento y calidad de explicación 13
6.8. Criterios de aceptación y análisis 14
6.9. Amenazas a la validez 14

7. Plan de trabajo **16**

8. Avance y resultados esperados **17**
8.1. Avance documental 17
8.2. Resultados que deberá producir la evaluación 17
8.3. Posibles conclusiones del experimento 17

9. Conclusiones del avance **18**

Referencias Bibliográficas **19**

A. Trazabilidad del corpus de 43 fichas **20**

ÍNDICE DE FIGURAS

6.1. Flujo propuesto para la evaluación. La selección y el entrenamiento se aprenden fuera de este recorrido y sus costos se informan aparte. 11

ÍNDICE DE TABLAS

4.1. Antecedentes que precisan el aporte del seminario. Las diferencias indicadas delimitan el experimento propuesto; no afirman ausencia universal de trabajo previo. . . . 8

6.1. Configuraciones a implementar. B3 se limitará a un subconjunto común si su costo impide evaluar todo el conjunto. 13

7.1. Plan actualizado por entregables. La ejecución de etapas posteriores depende de la auditoría de datos y del piloto. 16

1. INTRODUCCIÓN

Detectar un archivo malicioso es solo una parte del trabajo de un equipo de seguridad. Cuando una alerta puede llevar al aislamiento de un equipo o a la interrupción de un servicio, también interesa examinar qué elementos influyeron en la decisión. Los modelos de aprendizaje automático permiten reconocer patrones en los datos, pero su salida no siempre ofrece una justificación que pueda revisarse. Las técnicas de inteligencia artificial explicable, o XAI, buscan hacer accesible parte de ese comportamiento (Liu et al., 2025; Manthena et al., 2025).

En la clasificación de malware, una explicación puede mostrar la influencia de permisos, llamadas a funciones o atributos de un ejecutable. Ese resultado ayuda a inspeccionar el modelo, aunque no demuestra por sí solo qué hace el programa ni reemplaza un análisis forense. También introduce trabajo adicional: generar perturbaciones, volver a consultar el clasificador o calcular atribuciones requiere tiempo y memoria. Por eso, un sistema que predice con rapidez no necesariamente explica con la misma rapidez.

El interés de este seminario surge de esa diferencia. Se busca estudiar cuánto cuesta generar explicaciones y qué decisiones de diseño permiten reducir ese costo conservando información útil para examinar las predicciones. La pregunta tiene sentido incluso cuando el clasificador ya es eficiente, porque el comportamiento del explicador depende de su configuración, de la representación de entrada y del modelo que consulta.

La ampliación bibliográfica obliga a precisar la propuesta inicial. Kim y colaboradores emplean explicabilidad para seleccionar atributos de grafos; Ardito y colaboradores integran reducción, clasificación y auditoría mediante SHAP y LIME; y RFS-MD explora explicaciones basadas en reglas (Alhawari & Ebadinezhad, 2026; Ardito et al., 2026; Kim et al., 2026). Estos antecedentes impiden sostener que la integración de eficiencia y explicabilidad carece de soluciones previas. A la vez, sus objetivos y mediciones no equivalen a una comparación controlada del costo incremental de explicar con selección, destilación y asignación adaptativa de recursos.

El proyecto propone estudiar esa combinación. Primero se seleccionarán características para reducir la entrada del modelo. Luego se evaluará si un estudiante destilado conserva suficiente capacidad predictiva frente a un profesor y frente al mismo estudiante entrenado directamente. Finalmente se asignarán distintos presupuestos de explicación, atendiendo a la incertidumbre y a criterios de auditoría. El ahorro deberá comprobarse: mostrar menos variables o dejar casos sin explicar no será suficiente para demostrar una mejora.

La investigación mantendrá un alcance experimental. Los resultados sobre conjuntos públicos permitirán comparar configuraciones bajo condiciones controladas, pero no probarán por sí solos que el sistema funciona en un SOC real o que mejora las decisiones de sus analistas. Esta distinción es pertinente porque la calidad técnica de una explicación y su utilidad para una persona son dimensiones relacionadas, pero diferentes (Cecchi et al., 2026; Tayari & Zaied, 2026).

El informe presenta los fundamentos y el diseño experimental. El anexo vincula las 43 fichas con la propuesta y distingue su grado de respaldo.

2. DEFINICIÓN DEL PROBLEMA

2.1. Problema de investigación

El problema abordado es el costo adicional de generar explicaciones locales en la clasificación de malware. Ese costo puede adquirir relevancia cuando aumenta el número de muestras, se emplean representaciones extensas o el explicador necesita consultar repetidamente un modelo complejo. Su magnitud no debe darse por sentada: depende del algoritmo, del presupuesto de muestreo, del hardware y de la calidad exigida a la explicación.

La dificultad no se resuelve únicamente con un clasificador más pequeño. La reducción de características puede eliminar información relevante; un estudiante puede reproducir errores de su profesor; y un motor adaptativo puede reservar las explicaciones más completas para casos que no concentran todos los errores. C-GUARD muestra precisamente que pueden persistir predicciones benignas incorrectas con alta confianza. Su mecanismo adapta la detección, no la explicación, pero ofrece una advertencia pertinente para el diseño de una política selectiva (Imran et al., 2026).

Tampoco basta con comparar una versión optimizada frente a una alternativa innecesariamente costosa. Si se utiliza un clasificador de árboles, TreeSHAP completo constituye una referencia exigente. El beneficio de destilar debe contrastarse con un estudiante de igual capacidad entrenado sin destilación. Estas comparaciones permiten distinguir el aporte de cada componente del efecto de cambiar simplemente de modelo o explicador.

2.2. Pregunta e hipótesis de trabajo

La pregunta general es: *¿En qué medida una arquitectura que combina selección de características, destilación de conocimiento y explicación adaptativa reduce el costo incremental de XAI en clasificación de malware, manteniendo el rendimiento predictivo y la calidad explicativa dentro de tolerancias definidas antes de la prueba final?*

La hipótesis de trabajo plantea que esta combinación puede reducir la latencia de explicación y el consumo de recursos frente a líneas base competitivas. La hipótesis no supone un porcentaje de ahorro ni garantiza que todos los componentes aporten. Una configuración será útil si ofrece una mejora verificable y cumple las restricciones previamente fijadas; si un componente agrega costo sin mejorar ese equilibrio, el resultado también será relevante.

Se examinarán tres preguntas específicas: cuánto aporta la selección de atributos al costo de explicación; si destilar ofrece una ventaja frente al entrenamiento directo; y cómo cambia la relación entre costo y calidad cuando se modifica el presupuesto explicativo por muestra. La evaluación del tercer punto incluirá errores de alta confianza y el costo de las auditorías, no solo el promedio global.

2.3. Alcance y delimitaciones

La unidad experimental será una muestra representada mediante características tabulares y acompañada de su etiqueta. CICMalDroid y ClaMP se consideran candidatos principales por su presencia en el planteamiento original. Su versión, disponibilidad, etiquetas y archivos concretos deberán verificarse antes de fijar la evaluación. Android y Windows se tratarán por separado; no se

mezclan sus variables ni se supone transferencia directa entre plataformas.

El núcleo del trabajo abarca selección de atributos, comparación profesor–estudiante y explicación adaptativa. La caché se estudiará como extensión controlada, empezando por entradas idénticas. Metaheurísticas, aprendizaje incremental y ejecución distribuida no son requisitos del prototipo inicial. Esta delimitación permite atribuir los resultados a decisiones identificables y completar una evaluación manejable.

El prototipo no ejecutará acciones de contención ni se validará como un sistema de respuesta en producción. Tampoco se afirmará que una explicación identifica causas del comportamiento malicioso o que un modelo detecta amenazas de día cero sin un protocolo específico que lo demuestre.

3. MARCO TEÓRICO

3.1. Representación y clasificación de malware

El análisis estático obtiene información sin ejecutar el programa; el dinámico observa su comportamiento en un entorno de ejecución; y el híbrido combina ambas fuentes. Estas alternativas producen entradas distintas y tienen costos diferentes. Si una evaluación comienza con una tabla ya extraída, sus tiempos describen lo que ocurre desde esa tabla, no desde la recepción del archivo original.

La detección binaria distingue entre muestras benignas y maliciosas. La clasificación multiclase identifica categorías o familias según las etiquetas disponibles. Una elevada sensibilidad en la tarea binaria no implica un rendimiento equivalente al discriminar familias. La exactitud global tampoco describe por sí sola el comportamiento en clases minoritarias. Por eso se incluirán macro F1, resultados por clase y falsos positivos.

Las representaciones visuales, las secuencias y los grafos amplían las opciones de modelado. Sin embargo, una región de una imagen o una variable latente no siempre corresponde de forma directa a una característica comprensible del ejecutable. Esta distancia entre representación y significado condiciona la interpretación de las atribuciones (Kim et al., 2026; Ullah, Alsirhani et al., 2022).

3.2. Qué significa explicar una predicción

Una explicación local describe una decisión particular; una explicación global resume aspectos del comportamiento del modelo en un conjunto de casos. Ambas son útiles para preguntas diferentes. La importancia global de una variable no demuestra que esa variable haya determinado una alerta concreta. De manera similar, ordenar pesos de atención permite inspeccionar un modelo, pero no garantiza una explicación fiel ni causal (Liu et al., 2025; Tayari & Zaied, 2026).

Los modelos interpretables por diseño ofrecen estructuras que pueden examinarse directamente, como coeficientes o reglas. Los métodos post hoc construyen una explicación de un modelo ya entrenado. Ninguna de estas alternativas está libre de costos: extraer, ordenar y presentar información también consume recursos. En este proyecto se medirá ese trabajo cuando forme parte de la salida entregada.

3.3. SHAP y sus implementaciones

SHAP atribuye contribuciones a las características con respecto a una referencia y a una salida del modelo. La enumeración exacta de todas las coaliciones crece exponencialmente con el número de características. Esto no significa que toda ejecución de KernelSHAP enumere esas coaliciones: su implementación permite estimar atribuciones con un presupuesto de muestras. El costo efectivo dependerá de ese presupuesto, del conjunto de referencia y de las consultas al clasificador.[1]

TreeSHAP aprovecha la estructura de modelos de árboles compatibles. Su uso hace pertinente

[1] Documentación técnica consultada: https://shap.readthedocs.io/en/stable/generated/shap.KernelExplainer.html.

comparar la propuesta con explicaciones completas de un modelo tabular competitivo. No se supondrá que puede explicar de forma exacta un ensamble arbitrario solo porque alguno de sus componentes sea un árbol. Se registrará el objeto explicado, la salida utilizada y el tratamiento de dependencias entre variables.

Una atribución sobre el estudiante describe al estudiante. La semejanza de sus predicciones con las del profesor no convierte esa atribución en una explicación del profesor. Si se examina concordancia entre modelos, se informará como una propiedad adicional, separada de la fidelidad de la explicación a cada uno.

3.4. LIME y evaluación local

LIME aproxima el comportamiento del clasificador alrededor de una muestra mediante un modelo sencillo ajustado a perturbaciones. La elección del vecindario, su ponderación y el número de consultas influyen tanto en el costo como en el resultado. No se asumirá que LIME es siempre más rápido que SHAP, pues la comparación depende de las implementaciones y sus configuraciones (Liu et al., 2025).

En malware, modificar una variable tabular puede producir una combinación imposible en un ejecutable real. Por ello, el protocolo distinguirá las pruebas sobre representaciones de cualquier afirmación sobre programas funcionales. Las perturbaciones respetarán el tipo y rango de las variables, y se documentarán las dependencias que no sea posible preservar.

3.5. Selección, destilación y adaptación

La selección de características reduce el espacio de entrada, pero exige volver a entrenar y evaluar el modelo. Su efecto sobre el tiempo de explicación es una cuestión empírica. También se debe contar el costo de aprender la selección, aunque se realice fuera del camino de inferencia.

La destilación utiliza las salidas de un profesor para entrenar un estudiante. En el diseño propuesto se contrastará una pérdida basada en etiquetas reales con otra que incorpora probabilidades del profesor. La capacidad del estudiante, los datos y el presupuesto de ajuste se mantendrán comparables entre ambos casos. Un ensamble puede servir de profesor, pero su composición no lo hace intrínsecamente transparente.

La explicación adaptativa asigna recursos distintos según el caso. Para que tenga sentido como optimización, debe alterar el cálculo realizado, no solo acortar la lista de atributos que se muestra después de calcular una explicación completa. Además, requiere evaluar si el ahorro se obtiene a costa de explicaciones menos fieles o de excluir sistemáticamente determinados tipos de muestras.

3.6. Calidad técnica y utilidad humana

La fidelidad evalúa hasta qué punto una explicación refleja el comportamiento del modelo bajo un protocolo concreto. La estabilidad examina la consistencia ante repeticiones o cambios controlados. Ninguna de estas medidas demuestra por sí sola que un analista comprenda mejor una alerta. Las revisiones de Cecchi y de Tayari y Zaied resaltan la necesidad de distinguir estos planos (Cecchi et al., 2026; Tayari & Zaied, 2026).

4. ESTADO DEL ARTE

4.1. Corpus y criterio de síntesis

El material de partida contiene 43 fichas de artículos: 31 antecedentes de la primera recopilación y 12 incorporaciones MDPI cuya revisión en texto completo está documentada en el vault. El anexo identifica todas las fichas y su función en el argumento. Este número describe el inventario disponible; no equivale a 43 estudios experimentales homogéneos ni a 43 fuentes verificadas con el mismo nivel de detalle.

La síntesis se organiza por problemas de investigación. Los antecedentes antiguos se utilizan como mapa temático y se señalan cuando requieren contrastar metadatos o resultados. Las conclusiones que modifican directamente el diseño se apoyan principalmente en las doce fichas con PDF local y en sus localizadores de evidencia. Se evita trasladar porcentajes aislados de las fichas antiguas, porque sus condiciones experimentales no están documentadas de manera uniforme.

La recopilación no permite declarar una revisión sistemática terminada: no se dispone aquí de un registro completo de búsquedas, duplicados y exclusiones. Para cumplir el OE1 será necesario completar ese registro. Los artículos de seguimiento visual, segmentación vial y seguridad 5G se conservan como contexto metodológico, pero no se cuentan como evidencia directa de eficiencia XAI en malware.

4.2. De la representación del malware a la explicación

Las fichas de Gibert, Gaber, Vásquez Berríos y la revisión ACM identificada por el DOI 3677374 sitúan el trabajo dentro de la evolución de la detección basada en aprendizaje automático. La revisión de Manthena y colaboradores aborda específicamente explicabilidad y malware (Manthena et al., 2025). En conjunto, este grupo permite ordenar los problemas de representación, predicción y explicación, que a menudo aparecen mezclados al comparar sistemas.

DREBIN representa en el corpus la línea de modelos que permiten inspeccionar contribuciones sin recurrir necesariamente a un explicador agnóstico. Baghirov y MAL-XSEL se registran como antecedentes de aplicación de SHAP y LIME a clasificadores de malware. Su papel en esta propuesta es orientar comparaciones y preguntas; no se importan sus cifras como resultados reproducidos. La ficha atribuida a Thompson carece de identificador y datos editoriales suficientes, por lo que se conserva en el inventario sin utilizarla como respaldo de afirmaciones empíricas.

Los dos artículos de Ullah incorporados en la ampliación ofrecen un contraste concreto. El primero usa Word2vec y representaciones visuales de tráfico Android; el segundo emplea BERT, junto con características visuales. Ambos evalúan clasificadores por votación y aplican SHAP y LIME (Ullah, Alsirhani et al., 2022; Ullah, Ullah et al., 2022). No corresponden a un stacking de ejecutables PE de Windows. Sus visualizaciones ilustran la aplicación de XAI, pero no constituyen un benchmark separado de latencia de explicación ni una evaluación con analistas.

4.3. Modelos visuales, multimodales y eficiencia

Una parte amplia del corpus explora imágenes y combinaciones de representaciones. Aquí se ubican las fichas de EfficientNet, IMCMKCNN, IMCNN, MIRACLE, SACNN, Ravi y Alazab, CNN preentrenadas, DIDroid y Multi-Stream CNN. Los trabajos registrados como MIDALF, ensamble multimodal, análisis de comunidades y Cross-Modal CNN amplían esa línea hacia distintas formas de fusión. Estos antecedentes muestran la diversidad de alternativas reunidas, pero sus arquitecturas no deben interpretarse como pruebas automáticas de un mayor costo de XAI.

Alotaibi combina ConvNeXt-Tiny y atención cruzada para clasificar familias. Su artículo deja SHAP como trabajo futuro, por lo que no respalda una cifra de costo de explicación ni una comparación de SHAP con atención (Alotaibi, 2025). CyberSentinel sí informa parámetros, memoria y tiempo de inferencia en su configuración, pero esos valores describen el modelo visual, no el costo por explicación de SHAP o LIME (Basak & Han, 2024).

Las fichas de CNN-DMA y transferencia para IoT introducen restricciones de recursos como contexto. La de mitigación de riesgos con aprendizaje profundo plantea otra comparación de representaciones y modelos. Para el seminario, la consecuencia metodológica es medir las fases por separado y comprobar sus costos en un entorno común. No se deriva de este grupo que toda red profunda sea inadecuada ni que toda representación tabular resulte más eficiente.

4.4. Reducción y clasificación explicable: antecedentes cercanos

Kim y colaboradores seleccionan siete de trece atributos por nodo en grafos de llamadas de Android, usando información de métodos explicativos. El estudio reporta extracción e inferencia sobre grafos disponibles, y reconoce límites de generalización (Kim et al., 2026). Su aporte es cercano al primer nivel propuesto: la reducción orientada por explicabilidad ya tiene antecedentes. Los tiempos publicados no equivalen a medir el proceso completo desde el APK ni a aislar el costo de generar atribuciones.

Ardito y colaboradores constituyen otro antecedente directo. Integran características estáticas y dinámicas, reducción de variables, clasificación y auditoría con SHAP y LIME. Además, explicitan controles sobre la construcción del benchmark y la separación de datos (Ardito et al., 2026). Su trabajo obliga a abandonar la afirmación de que faltan sistemas integrados. La diferencia que interesa estudiar aquí es el costo incremental de explicar y la contribución de la destilación y de una política adaptativa bajo un mismo protocolo.

RFS-MD combina selección, ponderación basada en reglas y explicaciones RXAI en Android. También evalúa fidelidad mediante cambios en la probabilidad del modelo tras retirar atributos relevantes (Alhawari & Ebadinezhad, 2026). Ese resultado respalda incluir alternativas explicables por diseño y detallar las perturbaciones. No aporta un factor de aceleración de RXAI frente a SHAP o LIME que pueda trasladarse al seminario.

Cannarile y colaboradores comparan modelos de árboles y aprendizaje profundo sobre llamadas API tabulares, e informan tiempos de entrenamiento y predicción (Cannarile et al., 2022). Este antecedente justifica una línea base tabular competitiva. En el corpus antiguo, FCMSA con LightGBM y MC-KDFF orientan respectivamente la selección y la destilación; sus resultados particulares requieren verificación antes de una comparación cuantitativa. Destilar deberá aportar una ventaja frente a entrenar directamente el mismo estudiante.

4.5. Adaptación, confianza y robustez

La revisión de Liu contempla explicaciones ajustadas al contexto como línea de desarrollo; por tanto, la adaptación no se presenta como una idea sin precedentes (Liu et al., 2025). C-GUARD aporta un ejemplo distinto, pero pertinente, de asignación selectiva de cómputo: activa un detector adicional sobre ciertas predicciones benignas y utiliza SHAP para diagnóstico fuera de línea (Imran et al., 2026). No valida una política de explicación adaptativa; sí muestra por qué la confianza del clasificador no debe tomarse como garantía de acierto.

La ficha de AFA-MalGAN introduce el problema de evasión como antecedente pendiente de contraste. Su presencia, junto con C-GUARD y RFS-MD, aconseja examinar errores y límites del espacio de perturbaciones. La propuesta no promete robustez adversarial por incorporar XAI: explicar un modelo y protegerlo frente a ataques son problemas diferentes.

4.6. Síntesis comparativa y aporte delimitado

Antecedente	Aporte documentado	Qué queda por medir en esta propuesta
Kim et al.	Selección guiada por XAI; extracción e inferencia.	Costo del explicador y efecto de seleccionar atributos.
Ardito et al.	Reducción, fusión y auditoría SHAP/LIME.	Aporte incremental de destilación y adaptación.
Cannarile et al.	Comparación tabular y tiempos predictivos.	Explicación completa frente a presupuestos limitados.
RFS-MD	Reglas, scoring y fidelidad por perturbación.	Relación entre recursos y calidad en un protocolo común.
C-GUARD	Detección selectiva y análisis de evasión.	Auditoría de explicaciones en casos de alta confianza.
CyberSentinel y Alotaibi	Modelos visuales y fusión; recursos en el primero.	Separación entre costo de clasificar y explicar.

Tabla 4.1: Antecedentes que precisan el aporte del seminario. Las diferencias indicadas delimitan el experimento propuesto; no afirman ausencia universal de trabajo previo.

La oportunidad identificada consiste en evaluar una arquitectura concreta que articule los tres niveles y permita atribuir sus beneficios y pérdidas. La contribución esperada es un protocolo reproducible y un prototipo que expongan cuándo conviene reducir, destilar o limitar el presupuesto explicativo. No se busca demostrar que una combinación será superior en todos los casos. También interesa identificar situaciones en que TreeSHAP completo o un modelo interpretable sencillo resulten suficientes.

5. OBJETIVOS

5.1. Objetivo general

Diseñar, construir y validar un *framework* multinivel para reducir el costo computacional de la Inteligencia Artificial Explicable (XAI) en la clasificación de malware, con el fin de viabilizar el uso de modelos transparentes en operaciones de ciberseguridad que exigen respuestas rápidas.

5.2. Objetivos específicos

Se mantienen las dimensiones y el alcance de los objetivos registrados en el vault.

OE1. Estudio
Realizar una revisión sistemática de la literatura sobre el uso de la Inteligencia Artificial Explicable (XAI) en la detección de malware, para identificar los cuellos de botella computacionales y problemas de escalabilidad actuales.

OE2. Estudio
Definir un marco de referencia que establezca cómo se medirá el costo computacional de XAI (latencia, consumo de memoria, volumen de procesamiento) y la utilidad de las explicaciones (fidelidad y estabilidad) en escenarios de monitoreo continuo.

OE3. Desarrollo
Diseñar la arquitectura del *framework*, definiendo cómo interactúan sus tres componentes principales: la reducción de dimensionalidad, la destilación de conocimiento hacia modelos más ligeros y la estrategia de explicación adaptativa.

OE4. Desarrollo
Construir un prototipo funcional que integre estos tres niveles, asegurando que sea compatible con clasificadores de malware y con librerías estándar de explicabilidad, como SHAP y LIME.

OE5. Validación
Evaluar el sistema mediante experimentos sobre conjuntos de datos públicos, como CICMalDroid o ClaMP, para comprobar cuánta carga computacional se logra reducir en comparación con los enfoques de XAI tradicionales, sin sacrificar la precisión de la detección.

En la evaluación, la conservación del rendimiento se operacionalizará mediante márgenes de no inferioridad fijados antes de consultar la prueba final. La fidelidad y la estabilidad del OE2 se medirán como propiedades técnicas; demostrar utilidad humana requeriría un estudio adicional. El inventario de 43 fichas constituye un insumo del OE1, cuyo protocolo sistemático aún debe completarse.

6. METODOLOGÍA

6.1. Diseño general

La investigación será cuantitativa y experimental. Se compararán configuraciones sobre las mismas particiones, muestras de explicación y condiciones de ejecución. La variable principal será el costo incremental de explicar una predicción; el rendimiento del clasificador y la calidad explicativa actuarán como restricciones. Los procedimientos descritos en este capítulo son el diseño propuesto, no experimentos ya ejecutados.

6.2. Revisión y trazabilidad bibliográfica

Para completar el OE1 se documentarán fuentes de búsqueda, fechas, ecuaciones, duplicados y motivos de exclusión. Se propone combinar términos de malware, explicabilidad y eficiencia, y efectuar una búsqueda complementaria de selección y destilación para evitar excluir antecedentes que no usen la palabra XAI. Se diferenciarán estudios primarios, revisiones y trabajos de otros dominios.

Cada estudio seleccionado tendrá una ficha con identificador, tarea, datos, representación, modelo, explicador, hardware, métricas y limitaciones. Las cifras se acompañarán de tabla o página. Los conteos de un eventual diagrama PRISMA se obtendrán del registro propio; no se reconstruirán a partir de los 43 documentos reunidos ni de diagramas de otras revisiones.

6.3. Datos y prevención de fuga

CICMalDroid y ClaMP se evaluarán como conjuntos independientes. Antes de utilizarlos se registrarán versión, origen, licencia, huella de archivos, número efectivo de registros, clases y atributos. Se verificará si los datos disponibles corresponden a archivos originales o a características preextraídas. Cuando no se mida la extracción, esta exclusión se hará visible en el reporte de tiempos.

La preparación identificará duplicados, etiquetas inconsistentes y variables que revelen directamente la respuesta. Las muestras vinculadas por un mismo archivo o grupo de duplicación se mantendrán en una sola partición. Si existen fechas fiables, se preferirá una evaluación temporal adicional. Sin ellas, la partición agrupada y estratificada permitirá una comparación controlada, pero no acreditará generalización temporal.

Se propone reservar 70 % para entrenamiento, 15 % para validación y 15 % para prueba, sujeto a la cantidad efectiva de grupos y clases. La imputación, codificación, selección de atributos y cualquier remuestreo se ajustarán exclusivamente con entrenamiento. El ajuste de hiperparámetros usará particiones internas de ese conjunto. La validación se subdividirá o se empleará validación cruzada para separar calibración de probabilidades y selección de la política adaptativa. La prueba permanecerá cerrada hasta fijar el diseño.

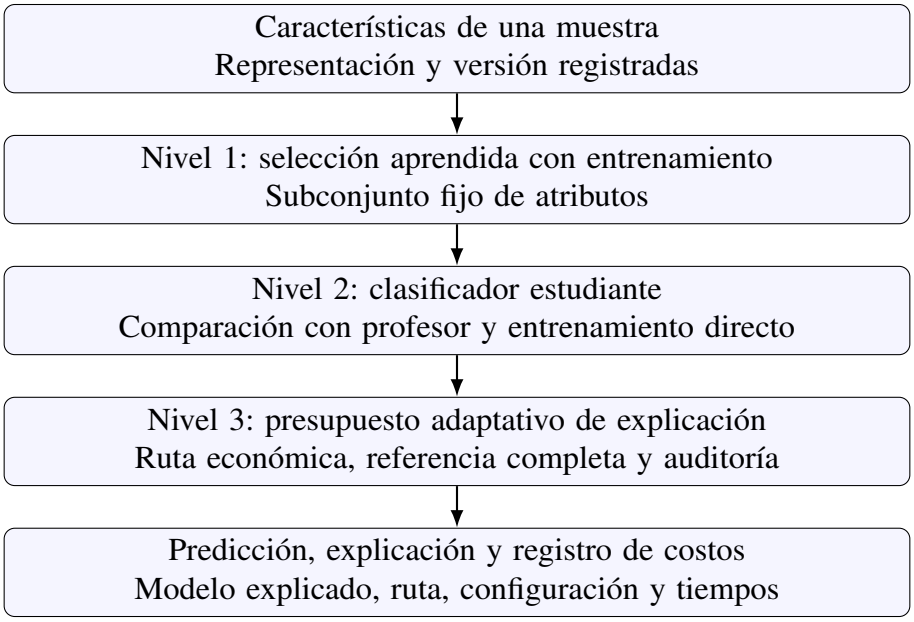


Figura 6.1: Flujo propuesto para la evaluación. La selección y el entrenamiento se aprenden fuera de este recorrido y sus costos se informan aparte.

6.4. Arquitectura multinivel

6.4.1. Nivel 1: selección de características

Se partirá de un filtro sencillo basado en importancia o información mutua y se evaluarán varios tamaños de subconjunto. La selección se recalculará dentro de cada partición de entrenamiento. Se comparará el mismo tipo de modelo con y sin reducción, manteniendo un presupuesto de ajuste equivalente.

Los atributos conservarán su nombre y descripción para relacionar las explicaciones con la representación original. La selección no se justificará solo por la disminución de dimensiones: deberá evaluarse su efecto en macro F1, sensibilidad y costo de explicación. Las metaheurísticas se considerarán una extensión si el filtro inicial deja una pregunta experimental concreta; su propio costo formará parte del balance.

6.4.2. Nivel 2: profesor y estudiante

El profesor será un clasificador de mayor capacidad, con un ensamble como candidato. Si se usa stacking, sus predicciones de entrenamiento para el metamodelo se generarán fuera de fold. LightGBM de capacidad limitada será el candidato inicial a estudiante por su compatibilidad con explicadores de árboles; su elección definitiva dependerá de la auditoría de los datos.

La destilación comparará una función supervisada con una combinación de etiquetas y probabilidades del profesor. Para una muestra se propone:

$$\mathcal{L} = \alpha \, \mathrm{CE}(y, p_s) + (1 - \alpha) \, \mathrm{CE}(p_t, p_s), \tag{6.1}$$

donde p_t y p_s son distribuciones del profesor y del estudiante, y α se selecciona sin consultar prueba. La implementación deberá comprobar que admite objetivos probabilísticos; no se asumirá que todas

las interfaces aceptan etiquetas suaves. Si se incorpora temperatura, su valor y transformación se documentarán como una variante adicional.

El estudiante destilado se contrastará con el mismo estudiante entrenado solo con etiquetas reales y con el profesor. Se registrarán el costo de formar el profesor, generar sus salidas y entrenar al estudiante. Si la destilación no mejora el equilibrio entre rendimiento y recursos, se informará sin atribuirle un beneficio por anticipado.

6.4.3. Nivel 3: explicación adaptativa

La primera implementación comparará LIME con dos presupuestos de perturbaciones y TreeSHAP completo como referencia independiente. La ruta económica usará un presupuesto menor de consultas; la ruta ampliada usará el presupuesto de referencia fijado en validación. Así, el costo se modifica antes de generar la explicación. Si TreeSHAP completo resulta más rápido y mantiene mejor calidad, ese resultado limitará la utilidad de adaptar LIME.

La política empleará probabilidades calibradas y un criterio de auditoría aleatoria sobre casos de alta confianza. Los umbrales, presupuestos y proporción de auditoría se seleccionarán en validación y quedarán congelados antes de la prueba. No se adoptarán 0,95 y 0,80 como garantías de seguridad. Se registrarán cobertura por ruta, clase, errores y calidad de explicación en cada franja.

Todas las muestras de la comparación principal recibirán una explicación; una política que omita explicaciones se evaluaría como escenario distinto, con cobertura explícita. La auditoría se seleccionará antes de conocer la etiqueta de prueba y su costo se incluirá en el promedio operacional. El sistema devolverá la predicción, el modelo explicado, el explicador, el presupuesto empleado y las variables relevantes. Las importancias globales no reemplazarán una explicación local sin señalarlo.

6.4.4. Extensión de caché

La caché inicial almacenará explicaciones de entradas idénticas e incluirá en su clave la versión del preprocesamiento, del modelo y del explicador. Una actualización invalidará los resultados afectados. Se medirán búsqueda, memoria, aciertos y recálculos con cargas frías y calientes, informando la proporción de repeticiones.

Reutilizar explicaciones de muestras parecidas exige una validación adicional: cercanía en el espacio de atributos no garantiza igualdad de contribuciones. Por ello, la caché por similitud queda fuera del experimento principal. No se usará para sostener un ahorro si no se comprueba el error que introduce.

6.5. Líneas base y ablaciones

Se evaluarán selección sola, destilación sola, adaptación sola y sus combinaciones, idealmente mediante un diseño factorial de presencia o ausencia de los tres componentes. Cada ablación mantendrá los demás factores constantes. La caché se agregará después, como experimento separado. MAL-XSEL y Ardito se utilizarán como antecedentes arquitectónicos; una implementación inspirada en ellos se identificará como adaptación y no como reproducción exacta.

ID	Configuración	Pregunta que permite responder
B0	Modelo lineal o árbol sencillo, con contribuciones o reglas.	¿Es suficiente una alternativa interpretable de menor complejidad?
B1	Estudiante directo y TreeSHAP completo.	¿Supera la propuesta una línea base eficiente?
B2	Estudiante directo y LIME de presupuesto fijo.	¿Qué aporta adaptar el presupuesto del mismo explicador?
B3	Modelo compatible con KernelSHAP, presupuesto fijo.	¿Cómo se comporta una explicación agnóstica en una muestra común?
P	Selección, estudiante destilado y política adaptativa.	¿Qué cambia al integrar los tres niveles?

Tabla 6.1: Configuraciones a implementar. B3 se limitará a un subconjunto común si su costo impide evaluar todo el conjunto.

6.6. Medición del costo computacional

Para cada muestra se distinguirán extracción o preparación, inferencia, enrutamiento, explicación y presentación:

$$t_{\text{total}} = t_{\text{prep}} + t_{\text{inf}} + t_{\text{ruta}} + t_{\text{exp}} + t_{\text{salida}}. \tag{6.2}$$

El costo incremental de XAI incluirá enrutamiento, explicación y la parte de presentación atribuible a XAI. La clasificación ya calculada se reutilizará cuando corresponda, evitando contar dos veces la misma inferencia. Si una fase no se mide, se indicará de forma explícita.

Se reportarán media, mediana y percentil 95 de latencia; memoria pico del proceso y diferencia respecto al estado previo al explicador; y tasa de procesamiento medida en pruebas por lote. El throughput se calculará como número de muestras finalizadas dividido por el tiempo total de la carga, no como el inverso de una latencia cuando exista paralelismo.

El factor de aceleración será $S = \bar{t}_{\text{base}}/\bar{t}_{\text{propuesta}}$ sobre las mismas muestras. También se informará la diferencia absoluta y qué fases abarca. El costo de las auditorías efectivamente activadas pertenecerá al tiempo operacional; las explicaciones adicionales generadas solo para evaluar calidad se contabilizarán como costo de evaluación fuera de línea.

Para el trabajo previo al despliegue se registrarán preparación, selección, entrenamiento, destilación y calibración. Si una variante ahorra tiempo por muestra, se podrá estimar el número de muestras necesario para amortizar su costo inicial adicional. Esta estimación solo se hará cuando el ahorro por muestra sea positivo y bajo una carga explícita.

6.7. Rendimiento y calidad de explicación

El rendimiento se medirá con macro F1, exactitud, sensibilidad a malware, falsos positivos y resultados por clase. En tareas binarias se añadirá AUC ROC y, cuando el desbalance lo haga pertinente, el área bajo precisión–recall. En multiclase se declarará el esquema de agregación y la correspondencia entre categorías y malware.

La fidelidad se estudiará perturbando los atributos destacados y observando la salida del mismo

modelo explicado. Para un conjunto de k atributos positivos relevantes se calculará:

$$D_k(x) = f_c(x) - f_c\big(x^{(-S_k)}\big), \tag{6.3}$$

donde c es la clase explicada, fijada en la muestra original, y $x^{(-S_k)}$ reemplaza esos atributos con una referencia derivada de entrenamiento. Se comparará con conjuntos aleatorios de igual tamaño. Se informarán signo, tamaño del conjunto, reglas de reemplazo y restricciones de validez. Esta medida describe sensibilidad del modelo bajo la perturbación elegida, no causalidad del malware.

Se evaluará además el error del sustituto local de LIME en un vecindario reservado distinto al usado para ajustarlo. Las coincidencias con TreeSHAP se tratarán como concordancia entre métodos, no como prueba de verdad. Para evitar cambios de escala inadvertidos se especificará si cada método explica probabilidades o márgenes; las comparaciones numéricas exigirán una salida y una semántica compatibles.

La estabilidad se medirá repitiendo explicaciones estocásticas con distintas semillas sobre una misma muestra y comparando el solapamiento de los primeros k atributos. Una segunda prueba usará perturbaciones pequeñas y válidas con predicción estable, cuando sea posible construirlas. Se reportarán ambas pruebas por separado, pues evalúan fuentes diferentes de variación.

6.8. Criterios de aceptación y análisis

Antes de abrir la prueba se fijarán márgenes máximos de pérdida predictiva y explicativa. Como punto de partida del piloto se propone un margen de un punto porcentual para macro F1 y sensibilidad a malware, y una tolerancia relativa de 5 % para las métricas de calidad cuya escala lo permita. Son decisiones iniciales de diseño, no umbrales validados por la literatura; se ratificarán o modificarán con el piloto y quedarán registradas antes de la evaluación final.

La configuración se seleccionará en validación buscando menor costo entre las alternativas que cumplan todas las restricciones. En prueba se informarán diferencias pareadas e intervalos de confianza del 95 %, remuestreando por grupos de muestras cuando exista dependencia. Para métricas donde un valor mayor es mejor, el límite inferior de la diferencia propuesta menos base deberá superar el margen negativo fijado. Para el ahorro de tiempo se informará si el intervalo respalda una reducción positiva. Si la incertidumbre no permite concluir, el resultado se declarará inconcluso.

Se distinguirán cinco semillas de entrenamiento como propuesta inicial y diez repeticiones de temporización sobre modelos ya fijados. Las repeticiones temporales no se tratarán como diez modelos independientes. Se registrarán calentamiento, procesos concurrentes, CPU/GPU, memoria, hilos, versiones, tamaños de lote y semillas. El orden de temporización se alternará para reducir el efecto de cambios en la carga del equipo.

6.9. Amenazas a la validez

El desbalance, la duplicación y las variables que revelan la etiqueta pueden inflar resultados. La partición y la selección dentro de entrenamiento buscan controlar esas amenazas. La ausencia de fechas o de un dataset externo limitará lo que pueda afirmarse sobre evolución temporal y generalización.

Las perturbaciones pueden salir de la distribución de datos, y distintas definiciones de referencia pueden alterar las atribuciones. Por eso se documentará el protocolo y se evaluará sensibilidad

a sus parámetros. El hardware y la implementación también condicionan el costo: los resultados describirán el entorno utilizado, no una latencia universal.

Finalmente, se examinarán muestras mal clasificadas y errores de alta confianza. Un buen promedio puede ocultar precisamente los casos en que más interesa una explicación detallada. Sin un estudio con personas, las conclusiones se limitarán a rendimiento, recursos y calidad técnica.

7. PLAN DE TRABAJO

Se conserva el horizonte general del proyecto original: cierre del Seminario de Título en diciembre de 2026 y desarrollo y validación durante el primer semestre de 2027. La planificación se actualiza al 4 de octubre de 2026. Las fechas siguientes son estimaciones de trabajo, no confirmación de actividades realizadas.

Período	Actividad y objetivo	Entregable verificable
Octubre 2026	Depurar las 43 fichas y completar el protocolo bibliográfico (OE1).	Registro de búsquedas, exclusiones y metadatos.
Octubre–noviembre 2026	Auditar datos, definir particiones y métricas (OE2).	Manifiesto de datos y protocolo reproducible.
Noviembre–diciembre 2026	Implementar líneas base y piloto de medición (OE2–OE3).	Informe de avance con mediciones identificadas como piloto.
Enero–febrero 2027	Desarrollar selección y comparación profesor–estudiante (OE4).	Módulos y resultados de ablación inicial.
Marzo–abril 2027	Integrar adaptación y auditoría; evaluar caché si corresponde (OE4).	Prototipo y configuración congelada.
Abril–mayo 2027	Ejecutar prueba final y análisis de calidad y recursos (OE5).	Resultados, intervalos y registro experimental.
Junio 2027	Redactar discusión, conclusiones y preparar defensa.	Memoria y material de presentación.

Tabla 7.1: Plan actualizado por entregables. La ejecución de etapas posteriores depende de la auditoría de datos y del piloto.

Al cierre de esta reformulación se dispone del corpus organizado y del diseño experimental escrito. No se considera completada la revisión sistemática ni se atribuyen avances de implementación sin evidencia de código y mediciones. El primer hito técnico será obtener una línea base reproducible; solo después se incorporarán los niveles de optimización.

Si el piloto muestra que TreeSHAP completo satisface el presupuesto disponible, la investigación comparará ese resultado con las variantes adaptativas. Si la destilación no aporta una ventaja, se conservará su evaluación como resultado y se priorizará la configuración más sencilla que cumpla las restricciones. La planificación admite estas decisiones sin cambiar la pregunta central.

8. AVANCE Y RESULTADOS ESPERADOS

8.1. Avance documental

El avance de esta etapa consiste en una propuesta reformulada a partir de 43 fichas bibliográficas, una síntesis que reconoce antecedentes cercanos y un protocolo que separa predicción, explicación y evaluación de calidad. Las doce incorporaciones con revisión en texto completo documentada en el vault permiten precisar varias afirmaciones del planteamiento inicial.

La principal modificación es la delimitación del aporte. La selección guiada por explicabilidad y los sistemas integrados ya tienen antecedentes. La propuesta se concentra en medir el efecto de combinar selección, destilación y adaptación frente a alternativas competitivas. También se corrige la caracterización de los artículos de Ullah, se distingue atención de explicación validada y se evita atribuir al explicador tiempos que corresponden a entrenamiento o inferencia.

8.2. Resultados que deberá producir la evaluación

La fase experimental deberá producir, para cada dataset y configuración, una tabla de rendimiento predictivo, una de costo por fase y una de calidad explicativa. Se acompañarán de la distribución de rutas adaptativas y de resultados para errores de alta confianza. Las ablaciones permitirán observar si la ganancia procede de seleccionar atributos, cambiar el entrenamiento del estudiante o reducir el presupuesto de explicación.

También se elaborará una curva de costo frente a calidad, variando el presupuesto de consultas y los umbrales de la política. Interesa identificar configuraciones que ahorren recursos manteniendo las restricciones, así como aquellas que aparentemente ahorran por deteriorar las explicaciones. Las tablas se completarán con mediciones reales; este avance no incluye porcentajes de mejora estimados como si fueran resultados.

8.3. Posibles conclusiones del experimento

La evaluación puede mostrar una mejora de la arquitectura completa, una ventaja de solo algunos componentes o ausencia de beneficio frente a una línea base eficiente. Cualquiera de estos escenarios responderá parte de la pregunta si el protocolo permite interpretarlo. Un resultado negativo de destilación o adaptación evitaría añadir complejidad innecesaria y ayudaría a delimitar cuándo conviene usar esas técnicas.

La interpretación considerará los intervalos de confianza, los márgenes predefinidos y los límites de cada dataset. No se extrapolará una mejora observada en un conjunto público a todos los tipos de malware ni a un SOC en operación.

9. CONCLUSIONES DEL AVANCE

La ampliación del corpus permite formular un problema más preciso. La literatura reunida ya contiene alternativas que combinan reducción, clasificación y explicabilidad, además de trabajos que miden recursos del modelo. El seminario debe reconocer esos avances y concentrarse en una pregunta comprobable: cuánto cuesta explicar y qué beneficio adicional ofrece integrar selección de atributos, destilación y asignación adaptativa de cómputo.

La arquitectura multinivel se mantiene, pero su evaluación adquiere un papel central. TreeSHAP completo y el estudiante entrenado directamente serán referencias necesarias para atribuir los efectos observados. La confianza del modelo se tratará como una señal que necesita calibración y auditoría. La reducción del número de variables mostradas no se confundirá con ahorro de cálculo, y las explicaciones del estudiante no se presentarán como explicaciones del profesor.

El aporte de esta etapa es documental y metodológico. Se ha definido qué se comparará, cómo se separarán los costos y qué controles permitirán evaluar rendimiento y calidad técnica. Quedan pendientes la depuración bibliográfica de los antecedentes antiguos, la auditoría de datos y la implementación experimental. Por tanto, todavía no corresponde afirmar que el sistema reduce latencia, conserva exactitud o mejora decisiones humanas.

La siguiente etapa deberá convertir este diseño en evidencia reproducible. Si el enfoque propuesto aporta una ventaja, será posible describir sus condiciones y límites. Si una solución más sencilla ofrece un equilibrio equivalente o mejor, la investigación también habrá producido una respuesta útil para diseñar clasificación de malware explicable con un costo justificado.

REFERENCIAS BIBLIOGRÁFICAS

Alhawari, A., & Ebadinezhad, S. (2026). AI-Driven Rule-Based Feature Scoring for Explainable and Adversarially Robust Android Malware Detection. *Electronics*, *15*(10), Artículo 2167. https://doi.org/10.3390/electronics15102167

Alotaibi, B. (2025). Multimodal Deep Learning Fusion for Accurate and Explainable Malware Family Classification. *Applied Sciences*, *15*(21), Artículo 11635. https://doi.org/10.3390/app152111635

Ardito, C., Loseto, G., Di Pietro, R., Epicoco, N., & Massaro, A. (2026). An Explainable Hybrid Pipeline for Malware Classification: Benchmark Construction, Feature Reduction, and Security-Oriented Evaluation. *Journal of Cybersecurity and Privacy*, *6*(3), Artículo 105. https://doi.org/10.3390/jcp6030105

Basak, M., & Han, M.-M. (2024). CyberSentinel: A Transparent Defense Framework for Malware Detection in High-Stakes Operational Environments. *Sensors*, *24*(11), Artículo 3406. https://doi.org/10.3390/s24113406

Cannarile, A., Dentamaro, V., Galantucci, S., Iannacone, A., Impedovo, D., & Pirlo, G. (2022). Comparing Deep Learning and Shallow Learning Techniques for API Calls Malware Prediction: A Study. *Applied Sciences*, *12*(3), Artículo 1645. https://doi.org/10.3390/app12031645

Cecchi, G., Benelli, F., Caronna, M., Palma, G., & Rizzo, A. (2026). Connecting the Dots: A Systematic Literature Review of Explainable AI, Cybersecurity, Human-Centered Design and Edge Computing. *Journal of Cybersecurity and Privacy*, *6*(3), Artículo 91. https://doi.org/10.3390/jcp6030091

Imran, M., Al-Essa, M., Franchini, F., & Pirlo, G. (2026). C-GUARD: Context-Adaptive Conformal Gating for Improving Robustness Against Evasive Windows PE Malware. *Future Internet*, *18*(8), Artículo 431. https://doi.org/10.3390/fi18080431

Kim, G., Yoon, D., Kwak, N., & Lee, B. (2026). Representation-Centric Approach for Android Malware Classification: Interpretability-Driven Feature Engineering on Function Call Graphs. *Applied Sciences*, *16*(6), Artículo 2670. https://doi.org/10.3390/app16062670

Liu, X., Huang, D., Yao, J., Dong, J., Song, L., Wang, H., Yao, C., & Chu, W. (2025). From Black Box to Glass Box: A Practical Review of Explainable Artificial Intelligence (XAI). *AI*, *6*(11), Artículo 285. https://doi.org/10.3390/ai6110285

Manthena, H., Shajarian, S., Kimmell, J., Abdelsalam, M., Khorsandroo, S., & Gupta, M. (2025). *Explainable Artificial Intelligence (XAI) for Malware Analysis: A Survey of Techniques, Applications, and Open Challenges* [Versión 3. Metadatos contrastados con arXiv; ficha original del vault correspondiente a la versión 2]. https://arxiv.org/abs/2409.13723v3

Tayari, Z., & Zaied, M. (2026). From Black Box to Clarity: A Systematic Review of Explainability Methods in Deep Convolutional Neural Networks. *Machine Learning and Knowledge Extraction*, *8*(8), Artículo 220. https://doi.org/10.3390/make8080220

Ullah, F., Alsirhani, A., Alshahrani, M. M., Alomari, A., Naeem, H., & Shah, S. A. (2022). Explainable Malware Detection System Using Transformers-Based Transfer Learning and Multi-Model Visual Representation. *Sensors*, *22*(18), Artículo 6766. https://doi.org/10.3390/s22186766

Ullah, F., Ullah, S., Naeem, M. R., Mostarda, L., Rho, S., & Cheng, X. (2022). Cyber-Threat Detection System Using a Hybrid Approach of Transfer Learning and Multi-Model Image Representation. *Sensors*, *22*(15), Artículo 5883. https://doi.org/10.3390/s22155883

A. TRAZABILIDAD DEL CORPUS DE 43 FICHAS

Este inventario vincula todas las fichas disponibles con la reformulación. Los identificadores de las fichas previas se transcriben como datos de localización y no certifican sus metadatos. Las doce incorporaciones MDPI cuentan con PDF local y revisión documentada en el vault. Para los demás antecedentes se evita convertir resúmenes o cifras sin localizador en evidencia verificada.

Los títulos siguientes son los nombres de las fichas de trabajo, no necesariamente los títulos editoriales. La bibliografía principal contiene las referencias que sustentan las afirmaciones centrales con metadatos consolidados. Los documentos de contexto externo y la referencia incompleta de Thompson se mantienen visibles sin forzar su uso como estudios de XAI en malware. La matriz complementaria en Markdown enlaza cada ficha original.

F01. ACM Computing Survey (3677374)

Línea: Revisión. **Respaldo:** Ficha previa; contraste pendiente.

Marco de técnicas; ficha breve que requiere completar metadatos.

Identificador registrado: 10.1145/3677374.

F02. AFA-MalGAN - Generación Adversarial Adaptativa con Optimización de Variedades

Línea: Robustez. **Respaldo:** Ficha previa; contraste pendiente.

Contexto de evasión; no se trasladan tasas de ataque sin verificar el original.

Identificador registrado: 10.1016/j.jksuci.2024.102194.

F03. Análisis de Comunidades de Malware con Características Multimodales

Línea: Multimodal. **Respaldo:** Ficha previa; contraste pendiente.

Representaciones y agrupación; no mide por sí mismo costo de explicación.

Identificador registrado: 10.1109/ACCESS.2020.2989606.

F04. Attention-Based Cross-Modal CNN - Detección de Malware sin Desensamblado

Línea: Multimodal. **Respaldo:** Ficha previa; contraste pendiente.

Contraste de fusión y atención; no se asume fidelidad explicativa.

Identificador registrado: 10.1109/ACCESS.2023.3252989.

F05. C-GUARD - Enrutamiento Adaptativo frente a Malware Evasivo

Línea: Adaptación. **Respaldo:** PDF local; revisión documentada. (Imran et al., 2026)

Auditar errores de alta confianza; adapta detección, no explicación.

Identificador registrado: 10.3390/fi18080431.

F06. CNN Basada en Atención para Clasificación Robusta de Malware - Ravi y Alazab

Línea: Visual. **Respaldo:** Ficha previa; contraste pendiente.

Atención como objeto de inspección, sin atribuirle costo nulo.

Identificador registrado: 10.1111/coin.12551.

F07. CNN-DMA - Modelo Ligero para Detección de Malware en IoT-5G

Línea: Recursos. **Respaldo:** Ficha previa; contraste pendiente.

Contexto IoT; cifras específicas pendientes de contraste.

Identificador registrado: 10.3390/s21196346.

F08. Comparación ML y DL sobre Llamadas API - Cannarile et al

Línea: Línea base. **Respaldo:** PDF local; revisión documentada. (Cannarile et al., 2022)

Justifica comparar árboles competitivos y separar tiempos predictivos de XAI.

Identificador registrado: 10.3390/app12031645.

F09. CyberSentinel - Red Visual de Dos Ramas y Atención

Línea: Recursos. **Respaldo:** PDF local; revisión documentada. (Basak & Han, 2024)

Reporta recursos del clasificador; no confundirlos con latencia XAI.

Identificador registrado: 10.3390/s24113406.

F10. DIDroid - Clasificación de Malware Android con Deep Image Learning

Línea: Android. **Respaldo:** Ficha previa; contraste pendiente.

Contexto de representación visual, sin equiparar tareas entre datasets.

Identificador registrado: 10.1145/3442520.3442522.

F11. DREBIN - Detección y Explicabilidad de Malware Android

Línea: Interpretable. **Respaldo:** Ficha previa; contraste pendiente.

Orienta la línea base interpretable; no se supone costo explicativo cero.

Identificador registrado: 10.14722/ndss.2014.23247.

F12. De Caja Negra a Caja de Cristal - Revisión XAI - Liu et al

Línea: Marco XAI. **Respaldo:** PDF local; revisión documentada. (Liu et al., 2025)

Taxonomía y antecedentes conceptuales de adaptación.

Identificador registrado: 10.3390/ai6110285.

F13. Detección Ligera de Malware Android con FCMSA y LightGBM

Línea: Selección. **Respaldo:** Ficha previa; contraste pendiente.

Orienta alternativas tabulares; métricas antiguas pendientes de contraste.

Identificador registrado: 10.1016/j.eij.2024.100560.

F14. EfficientNet CNN para Clasificación de Malware Basada en Imágenes

Línea: Visual. **Respaldo:** Ficha previa; contraste pendiente.

Contexto de eficiencia arquitectónica; no prueba ahorro del explicador.

Identificador registrado: 10.1016/j.jisa.2022.103306.

F15. Ensemble Deep Neural Network Multimodal para Malware

Línea: Multimodal. **Respaldo:** Ficha previa; contraste pendiente.

Contexto de ensambles; no se importa un costo XAI no medido.

Identificador registrado: 10.1038/s41598-025-96203-3.

F16. Evaluación de Modelos CNN Preentrenados en Detección de Malware

Línea: Visual. **Respaldo:** Ficha previa; contraste pendiente.

Comparación de arquitecturas; distinguir operaciones de operaciones por segundo.

Identificador registrado: 10.3390/app14062614.

F17. Evolución del Machine Learning en Detección de Malware - Gibert et al

Línea: Revisión. **Respaldo:** Ficha previa; contraste pendiente.

Panorama histórico de representaciones y detección.

Identificador registrado: 10.1016/j.jnca.2019.102526.

F18. Explicabilidad en CNN - Revisión Sistemática - Tayari y Zaied

Línea: Calidad XAI. **Respaldo:** PDF local; revisión documentada. (Tayari & Zaied, 2026)

Fidelidad, estabilidad y límites de evaluación humana; alcance multidominio.

Identificador registrado: 10.3390/make8080220.

F19. Fusión Multimodal ConvNeXt y Calibración - Alotaibi

Línea: Multimodal. **Respaldo:** PDF local; revisión documentada. (Alotaibi, 2025)

ConvNeXt y atención; SHAP queda como trabajo futuro.

Identificador registrado: 10.3390/app152111635.

F20. Generación de Datasets de Seguridad 5G - Amponis et al

Línea: Contexto externo. **Respaldo:** Ficha previa; contraste pendiente.

Calidad de datasets de seguridad 5G; no es evidencia directa de XAI en malware.

Identificador registrado: 10.1016/j.aeue.2023.154913.

F21. IMCMKCNN - CNN Ligera Multi-Escala para Malware

Línea: Visual. **Respaldo:** Ficha previa; contraste pendiente.

Arquitectura ligera como contexto; ahorro XAI no inferido automáticamente.

Identificador registrado: 10.1016/j.aej.2024.12.010.

F22. IMCNN - Clasificación Inteligente de Malware con CNNs y Ensembles

Línea: Visual. **Respaldo:** Ficha previa; contraste pendiente.

Ensamble visual como antecedente temático, no baseline reproducido.

Identificador registrado: 10.1016/j.comcom.2023.12.036.

F23. Ingeniería de Características Explicable sobre FCG - Kim et al

Línea: Selección. **Respaldo:** PDF local; revisión documentada. (Kim et al., 2026)

Antecedente directo de selección guiada por XAI en grafos.

Identificador registrado: 10.3390/app16062670.

F24. Investigación Comprehensiva Detección de Malware con XAI

Línea: XAI en malware. **Respaldo:** Ficha previa; contraste pendiente.

Aplicación tabular de XAI; título y fecha requieren normalización bibliográfica.

Identificador registrado: 10.1016/j.csa.2024.100072.

F25. MAL-XSEL Framework

Línea: XAI en malware. **Respaldo:** Ficha previa; contraste pendiente.

Antecedente de stacking con XAI; no se declara reproducción experimental.

Identificador registrado: 10.3390/pr13051329.

F26. MC-KDFF - Clasificación de Malware con Destilación de Conocimiento y Fusión

Línea: Destilación. **Respaldo:** Ficha previa; contraste pendiente.

Motiva profesor–estudiante; cifras de ahorro de la ficha no se reutilizan.

Identificador registrado: 10.1109/ACCESS.2025.3546702.

F27. MIDALF - Fusión Multimodal de Imagen y Audio para Malware

Línea: Multimodal. **Respaldo:** Ficha previa; contraste pendiente.

Contexto de fusión; no atribuirle latencia de explicación sin medición.

Identificador registrado: 10.1186/s13635-025-00188-5.

F28. MIRACLE - Reconocimiento de Imágenes de Malware por Extracción en Capas

Línea: Visual. **Respaldo:** Ficha previa; contraste pendiente.

Representación estructurada; autoría y datos editoriales por completar.

Identificador registrado: 10.1007/s10618-024-01078-z.

F29. Malware Android con BERT y Representación Visual - Ullah et al

Línea: XAI en Android. **Respaldo:** PDF local; revisión documentada. (Ullah, Alsirhani et al., 2022)

BERT, tráfico y votación; distingue aplicación de XAI de su costo.

Identificador registrado: 10.3390/s22186766.

F30. Malware Android con Word2vec y Tráfico de Red - Ullah et al

Línea: XAI en Android. **Respaldo:** PDF local; revisión documentada. (Ullah, Ullah et al., 2022)

Corrige la atribución a PE y stacking: tráfico Android y votación.

Identificador registrado: 10.3390/s22155883.

F31. Mitigación de Riesgos de Malware con Deep Learning

Línea: Clasificación. **Respaldo:** Ficha previa; contraste pendiente.

Antecedente temático de aprendizaje profundo; datos editoriales por completar.

Identificador registrado: 10.3390/electronics12143166.

F32. Multi-Stream CNN para Clasificación de Familias de Malware Android

Línea: Android. **Respaldo:** Ficha previa; contraste pendiente.

Representaciones por flujos; revista y resultados requieren contraste.

Identificador registrado: 10.1109/TII.2021.3139820.

F33. Pipeline Híbrido Explicable y Benchmark sin Fuga - Ardito et al

Línea: Integración. **Respaldo:** PDF local; revisión documentada. (Ardito et al., 2026)

Antecedente cercano de reducción, fusión y auditoría sin fuga.

Identificador registrado: 10.3390/jcp6030105.

F34. RFS-MD - Reglas Explicables y Robustez Android

Línea: Reglas y calidad. **Respaldo:** PDF local; revisión documentada. (Alhawari & Ebadinezhad, 2026)

Alternativa con reglas; su fidelidad es cambio de probabilidad, no tasa de acierto.

Identificador registrado: 10.3390/electronics15102167.

F35. Revisión Sistemática de Detección de Malware - Vásquez Berríos et al

Línea: Revisión. **Respaldo:** Ficha previa; contraste pendiente.

Contexto metodológico; no transferir conteos PRISMA a la revisión propia.

Identificador registrado: 10.3390/app15147747.

F36. Revisión Sistemática de Detección de Malware con IA - Gaber et al

Línea: Revisión. **Respaldo:** Ficha previa; contraste pendiente.

Panorama de detección con IA; completar contraste de metadatos.

Identificador registrado: 10.1145/3638552.

F37. SACNN - Clasificación de Imágenes de Malware con VGG19 y Atención Espacial

Línea: Visual. **Respaldo:** Ficha previa; contraste pendiente.

Atención espacial como contexto, sin equipararla automáticamente a explicación fiel.

Identificador registrado: 10.3390/electronics10192444.

F38. Segmentación de Escenas Basada en Transformers y Restricciones de Tiempo Real

Línea: Contexto externo. **Respaldo:** Ficha previa; contraste pendiente.

Analogía de recursos en visión; excluida de evidencia directa de malware.

Identificador registrado: 10.3390/wevj15110516.

F39. Seguimiento Multi-Objetivo con Transformer y Auto-Atención

Línea: Contexto externo. **Respaldo:** Ficha previa; contraste pendiente.

Conceptos de atención; excluido de evidencia directa de malware.

Identificador registrado: 10.3390/rs14246354.

F40. Transfer Learning para Detección de Malware Basada en Imágenes en IoT

Línea: Recursos. **Respaldo:** Ficha previa; contraste pendiente.

Contexto IoT; no demuestra ahorro XAI transferible.

Identificador registrado: 10.3390/s23063253.

F41. XAI Ciberseguridad Diseño Humano y Edge - Cecchi et al

Línea: Utilidad humana. **Respaldo:** PDF local; revisión documentada. (Cecchi et al., 2026)

Distingue calidad técnica de utilidad con analistas.

Identificador registrado: 10.3390/jcp6030091.

F42. XAI en Detección de Malware - Thompson et al

Línea: Referencia incompleta. **Respaldo:** Ficha previa; contraste pendiente.

Sin DOI ni editorial identificables en la ficha; no sustenta conclusiones empíricas.

Identificador registrado: Por completar.

F43. XAI for Malware Analysis Survey

Línea: Revisión XAI. **Respaldo:** Metadatos web contrastados; síntesis del vault.

Síntesis de XAI en malware; metadatos contrastados con arXiv v3.

Identificador registrado: arXiv:2409.13723.